DELESCLUSE Melchior
DERNONCOURT Tom
SINI Sandra

Data Cleansing & Data Preparation

Projet : Pipeline de qualité de données pour un Hedge Fund

1. Rapport d'audit

Objectif & Positionnement Data Cleansing

Le Data Cleansing est défini comme un processus de détection, correction et suppression des données incorrectes, incomplètes ou mal formatées avant utilisation.
Dans ce projet, il intervient avant l'entraînement du modèle de risque, conformément au principe : GIGO (Garbage In, Garbage Out), qui précise qu'un modèle ne compense jamais des données de mauvaise qualité.

Data Dictionary

Colonne	Type	Source	Description	Règle de validation
`trade_id`	String	Murex	Identifiant unique de la transaction	UNIQUE, non null : une transaction = un identifiant, sinon le risque est compté 2 fois
`counterparty_id`	String	Murex	Identifiant de la contrepartie	non null
`counterparty_name`	String	Refinitiv	Nom de l'entreprise (PII indirecte)	pseudonymisation obligatoire
`isin`	String	Bloomberg	Code ISIN de l'instrument (12 caractères)	longueur = 12, alphanumérique
`trade_date`	Date	Murex	Date d'exécution du trade	≤ `settlement_date`
`settlement_date`	Date	Murex	Date de règlement (T+2 pour actions)	≥ `trade_date`

asset_class	Category	Murex	equity / bond / derivative / fx	doit appartenir uniquement à une des quatre catégories, normalisation des noms des catégories
notional_eur	Float	Murex	Montant notionnel en euros	> 0
price	Float	Bloomberg	Prix d'exécution	> 0
quantity	Integer	Murex	Quantité d'instruments	> 0, on ne peut pas acheter/vendre une quantité négative
bid	Float	Bloomberg	Prix acheteur au moment du trade	> 0, on ne peut pas acheter à un prix négatif
ask	Float	Bloomberg	Prix vendeur au moment du trade	> 0, on ne peut pas vendre à un prix négatif
mid_price	Float	Bloomberg	(bid + ask) / 2 théorique	> 0, le prix moyen ne peut pas être négatif
volume_j	Integer	Bloomberg	Volume journalier de l'instrument	> 0
volatility_30d	Float	Bloomberg	Volatilité historique 30 jours (%)	> 0, la volatilité ne peut pas être négative
credit_rating	Category	Refinitiv	AAA / AA / A / BBB / BB / B / CCC / D	doit être une des valeurs proposées dans la description
default_flag	Integer	Refinitiv	1 = défaut observé dans les 90j, 0 = sain	0 ou 1, pas d'autre valeur
sector	String	Refinitiv	Secteur économique (GICS)	doit appartenir à une catégorie de secteur économique (ex. : Healthcare, Energy…), format normalisé
country_risk	Float	Refinitiv	Score de risque pays (0-100)	>= 0 et <= 100
trader_id	String	Murex	Identifiant du trader (données internes)	non null

Profiling

Taux NaN

Les trois colonnes qui comportent des valeurs NaN sont :

- `volatility_30d` : 13.72% (1228 lignes)
- `credit_rating` : 14.98% (1341 lignes)
- `country_risk` : 0.30% (24 lignes)

Distribution et cardinalité

- `asset_class` : 20 valeurs uniques

```
fx                  1533
equity              1510
bond                1407
derivative          1367
Foreign Exchange     212
Fixed Income         209
DERIV                206
EQ                   204
BOND                 202
Derivative           200
EQUITY               200
Equities             198
FOREX                197
OPT                  193
Equity               191
Derivatives          190
Bond                 187
FX                   185
FI                   183
Fx                   176
```

- `credit_rating` : 8 valeurs uniques

```
BBB    2144
A      1642
NaN    1341
BB     1247
B       845
AA      659
CCC     594
D       311
AAA     167
```

- `sector` : 8 valeurs uniques

```
Technology                1869
Healthcare                1717
Financials                1364
Industrials               1196
Utilities                  934
Consumer Discretionary     902
Energy                     559
Real Estate                409
```

min/max

	notional_eur	price	quantity	bid	ask	mid_price	volume_j	country_risk
count	8.950000e+03	8950.0000	8950.0000	8950.0000	8950.0000	8950.0000	8.950000e+03	8932.0000
mean	3.383195e+06	137.6065	25103.4733	135.0551	135.3865	136.4292	2.495812e+06	103.9267
std	6.176136e+06	206.9537	14302.4517	199.7472	200.3053	202.4357	1.445374e+06	2590.1672
min	-3.491747e+07	0.5740	105.0000	0.5738	0.5746	0.5742	1.007900e+04	-1.0000
25%	5.004500e+04	1.4784	12807.0000	1.4764	1.4706	1.4784	1.233639e+06	18.4000
50%	8.866572e+05	48.4013	25167.0000	48.0754	48.1586	48.3931	2.497022e+06	38.1000
75%	3.542871e+06	112.9767	37409.0000	112.3945	112.6677	112.9787	3.774046e+06	51.8000
max	3.716779e+07	1771.0427	49996.0000	799.0000	802.5225	1181.6051	4.998970e+06	99999.0000

Corrélations entre colonnes liées (bid/ask/mid)

	bid	**ask**	**mid_price**	**price**
bid	1.0000	1.0000	0.9971	0.9860
ask	1.0000	1.0000	0.9971	0.9860
mid_price	0.9971	0.9971	1.0000	0.9829
price	0.9860	0.9860	0.9829	1.0000

Plan de traitement des données

Anomalies

Catégorie	**Colonne**	**Volumétrie estimée**	**Criticité métier**	**Description**
Classique : doublons	trade_id	200 doublons exacts	HAUTE	Doublons migration Murex
Classique : valeurs sentinelles	volatility_30d, country_risk	14 lignes	MOYENNE	Valeurs NAN Bloomberg
Classique : format, normalisation	asset_class	1800 lignes	HAUTE	20 valeurs uniques au lieu de 4 (casse inconsistante)
Classique : valeurs manquantes	credit_rating, volatility_30d	15%	HAUTE	Valeurs manquantes (NAN)
Métier financier : incohérence	settlement_data , trade_date	81 lignes	HAUTE	Dates incohérentes (settlement_date < trade_date est impossible)
Métier financier : incohérence	bid, ask	121 lignes	HAUTE	bid > ask, impossible

Métier financier : incohérence calcul	mid_price	329 lignes	HAUTE	mid_price = (bid + ask) / 2, erreur de calcul Bloomberg
Métier financier : incohérence	price	270 lignes	HAUTE	price hors fourchette bid - ask, impossible
Métier financier : incohérence	notional_eur	42 lignes	HAUTE	négatif sans short, impossible
Avancée : contradiction	credit_rating	97 lignes	HAUTE	AAA avec default_flag = 1, contradiction
Avancée : valeurs aberrantes	price, volume_j, volatility_30d	0 lignes	HAUTE	outliers multivariés

Stratégie de traitement

Gestion des doublons
Les valeurs doublons peuvent être supprimées.

Gestion des valeurs manquantes/sentinelles
Tout d'abord, toutes les valeurs sentinelles ont été remplacées par des vraies valeurs nulles.

Pour les valeurs manquantes de la colonne `volatility_30d`, elles ont été remplacées par la valeur médiane et une colonne `was_missing` a été ajoutée pour garder une trace de la correction.

Pour les valeurs manquantes de la colonne `credit_rating`, les valeurs ont été remplacées par une nouvelle valeur "NR" (Not Rated).

Gestion des incohérences
Pour les valeurs incohérentes de la colonne `settlement_date` nous avons, si `settlement_date` < `trade_date`, corrigé la date de `settlement_date` pour qu'elle soit égale à `trade_date` + deux jours, selon la règle des marchés des actions.

Pour les valeurs incohérentes de la colonne `bid`, pour les enregistrements où `bid > ask`, nous avons permuté les valeurs, car l'inverse est impossible.

Le calcul de `mid_price` a été corrigé et est devenu : (`bid` + `ask`) / 2. Le calcul initial de Bloomberg était incorrect.

Les valeurs incohérentes de `price` (valeurs aberrantes), elles ont été remplacées par `mid_price` car l'exécution hors marché est impossible.

Pour la colonne `notional_eur`, on remplace les valeurs négatives par leur valeur absolue si la position n'était pas explicitement flaguée comme "short". On la flag ensuite pour conserver l'information.

Pour la colonne `credit_rating`, si une valeur est à AAA alors que le `default_flag` est à 1 (ce qui est contradictoire), on remplace le AAA par CCC et on garde une trace de la modification (avec le flag "`rating_degraded_due_to_default`").

Normalisation

Le référentiel `asset_class` a été normalisé en se basant sur ses 4 valeurs valides :

```
"mapping": {
  "equity": "equity",
  "equities": "equity",
  "eq": "equity",
  "bond": "bond",
  "fi": "bond",
  "fixed income": "bond",
  "derivative": "derivative",
  "derivatives": "derivative",
  "deriv": "derivative",
  "opt": "derivative",
  "fx": "fx",
  "forex": "fx",
  "foreign exchange": "fx"
}
```

Gestion des outliers

Nous avons appliqué une stratégie de winsorisation sur les valeurs aberrantes des colonnes `price`, `volume_j`, `notional_eur` et `volatility_30d`. Nous avons ensuite passé ces colonnes dans un modèle d'IsolationForest pour détecter les anomalies multivariées. Ces dernières sont flaguées dans une colonne "`is_anomaly_multivaried`". Aucune suppression n'a été faite car le Risk Officer fera une revue sur ces données.

Pseudonymisation

Les colonnes `trader_id` et `counterparty_name` ont été pseudonymisées pour respecter le RGPD (Article 4).

2. Validation Great Expectation

Expectation	Colonne	Description	Validation
A > B or equal = True	`settlement_date`, `trade_date`	Un règlement ne peut pas être antérieur au trade.	PASS
A > B	`ask`, `bid`	La fourchette de prix doit toujours être dans le bon sens.	PASS
A est dans le set	`price_valid`	création d'une colonne `price_valid` qui vérifie si `price` est >= de (`bid` * 0.995) et <= (`ask` * 1.005), `set` = True ou False	PASS
A est dans le set	`mid_price_valid`	création d'une colonne `mid_price_valid` avec une tolérance d'un écart < 1% du mid théorique.	PASS
A est dans le set	`asset_class`	`set` = equity, bond, derivative, fx	PASS
A est dans le set	`rating_valid`	création d'une colonne `rating_valid` qui vérifie si `credit_rating` est AAA, AA ou A et `default_flag` à 1, `set` = True ou False	PASS
A est compris entre les valeurs	`notional_eur`	valeur minimale = 0, elle doit être strictement positive	PASS
A est compris entre les valeurs	`country_risk`	valeur minimale = 0, valeur maximale = 100	PASS
A match l'expression régulière	`isin`	regex = `^[A-Z]{2}[A-Z0-9]{10}$`	PASS
A est compris entre les valeurs	`volatility_30d`	valeur minimale = 0.1, valeur maximale = 200	PASS
A est dans le set	`pii_absent`	Les colonnes counterparty_name et trader_id ne doivent PAS exister dans le dataset final (remplacées par leurs versions hashées), set = True	PASS

A est dans le set	`global_completeness_valid`	Le taux de complétude global (toutes colonnes confondues) doit être supérieur à 90%. set = True	PASS

3. Note réglementaire BCBS 239

Le département Data Engineering de QuantAxis Capital a consolidé trois flux de données hétérogènes : Bloomberg Terminal (CSV), Murex (SQL) et Refinitiv Eikon (API JSON), le tout dans un entrepôt unifié destiné à alimenter un nouveau modèle de scoring de risque de contrepartie. L'analyse préalable a révélé des anomalies de données conséquentes compromettant la qualité des prédictions. Le pipeline TradeCleanse a été conçu pour auditer et nettoyer ce dataset avant tout nouvel entraînement.

Principe 2 - Exactitude et intégrité des données

BCBS 239 exige que les données de risque soient exactes, réconciliables avec les sources et exemptes d'erreurs systémiques. Le pipeline TradeCleanse adresse ce principe à travers les transformations suivantes :

Principe 2	**Exactitude et intégrité**
Anomalie	11 types d'anomalies identifiés lors de l'audit initial, couvrant 3 niveaux de complexité croissante
Sentinelles	Remplacement des valeurs sentinelles (99999, N/A, #N/A, 0.0…) par des vraies valeurs nulles (NaN)
Cohérence	Détection et correction des incohérences (par exemple : `settlement_date` < `trade_date`) et des violations de règles opérationnelles inviolables dans les marchés financiers (`bid` > `ask`)
Recalcul	Recalcul du `mid_price` à partir de `bid` et `ask` et filtrage des prix d'exécution aberrants
Contradictions	Correction des contradictions telles que `credit_rating` = "AAA" et `default_flag` = 1
Doublons	Suppression de 200 doublons sur la colonne `trade_id`, en conservant l'enregistrement le plus récent

→ Chaque transformation est soumise à une suite de 14 Great Expectations passant sur le dataset nettoyé final. Toute régression déclenche un blocage automatique du pipeline avant ingestion.

Principe 3 - Complétude des données

BCBS 239 impose que les données de risque soient complètes et que toute donnée manquante soit identifiée, documentée et traitée de manière argumentée. Le tableau ci-dessous présente les taux de complétude atteints sur les colonnes obligatoires du modèle :

Colonne obligatoire	Taux de complétude (après nettoyage)	Méthode d'imputation	Statut
`default_flag`	100%	Aucune	Conforme
`trade_id`	100%	Aucune	Conforme
`counterparty_id`	100%	Aucune	Conforme
`trade_date`	100%	Aucune	Conforme
`asset_class`	100%	Remplacement des valeurs nulles par le mode et ajout d'un flag "`_was_missing`"	Conforme
`notional_eur`	100%	Correction des valeurs négatives non-short	Conforme
`credit_rating`	≥ 95,0 %	Remplacement par NR (Not Rated) et flag "`_was_missing`"	Conforme
`volatility_30d`	≥ 95,0 %	Médiane par `asset_class` et flag binaire	Conforme
`country_risk`	≥ 95,0 %	Médiane globale et flag "`_was_missing`"	Conforme

Les colonnes avec un taux de valeurs manquantes inférieur à 20 % sont imputées par médiane (variables continues) ou mode sectoriel (variables catégorielles), avec ajout d'un flag binaire "`_was_missing`" préservant l'information de l'absence. Cette approche garantit que le modèle ne confond pas une donnée imputée avec une valeur observée, conformément aux exigences d'intégrité de BCBS 239.

Principe 6 - Adaptabilité du pipeline

BCBS 239 exige que les systèmes de données de risque soient suffisamment flexibles pour s'adapter à de nouvelles exigences réglementaires, de nouvelles sources ou de nouveaux instruments. L'architecture TradeCleanse répond à ce principe par trois mécanismes :

Principe 6	Adaptabilité
Configuration déclarative	La classe `DataCleaner` est pilotée par un dictionnaire de configuration JSON déclaratif (règles métier, seuils, colonnes à pseudonymiser, référentiels autorisés). L'ajout d'une nouvelle source ou d'une nouvelle règle ne nécessite aucune modification du code applicatif.
Multi-sources	Le module de collecte simule nativement les trois sources existantes (CSV Bloomberg, SQL Murex, JSON Refinitiv via `pd.json_normalize()`). L'ajout d'un 4ème fournisseur se fait par extension du connecteur correspondant, sans refactoring de la chaîne de nettoyage.
Great Expectations	Le référentiel de validation est externalisé dans une suite Great Expectations versionnée. De nouvelles Expectations s'ajoutent en YAML sans toucher au pipeline Python.
Versionning	Le pipeline est versionné sur Git avec au minimum 5 commits distincts, permettant un retour arrière complet sur n'importe quelle version des règles de nettoyage en cas d'audit rétrospectif.

Traçabilité - Audit et logging

La traçabilité est une exigence transversale de BCBS 239. Le pipeline TradeCleanse implémente une traçabilité à quatre niveaux :

Niveau de traçabilité	Implémentation dans TradeCleanse
Transformation	Chaque étape de la classe `DataCleaner` produit un log horodaté (nb de lignes avant/après, nature de la transformation, colonnes affectées) stocké dans un rapport JSON structuré
Lignage des données	La colonne source est ajoutée dès la consolidation multi-sources (`bloomberg_csv`, `murex_sql`, `refinitiv_json`), permettant de retracer l'origine de chaque enregistrement jusqu'à la source système
Immutabilité du brut	Le dataset brut `tradecleanse_raw.csv` n'est jamais modifié. Le pipeline travaille exclusivement sur une copie `df_copy()`, garantissant la reproductibilité complète de la chaîne de traitement
Rapport qualité avant/après	La fonction `quality_report(df_before, df_after)` produit un Data Quality Score normalisé (0-100) comparant taux de complétude globale, nombre de doublons résiduels et violations de règles métier, versionnée à chaque exécution

Conformément à l'article 25 du RGPD (Privacy by Design), les colonnes `counterparty_name` et `trader_id` sont remplacées par un hash SHA-256 avant toute analyse ou modélisation. Les colonnes originales sont supprimées du dataset ML. Cette mesure est complémentaire aux exigences BCBS 239 et constitue une contrainte non négociable du projet.

→ Le pipeline TradeCleanse répond aux principes 2, 3 et 6 de BCBS 239 par une approche systématique de détection, correction et documentation des anomalies de données. Le Data Quality Score final (100%) atteint un niveau de conformité supérieur au seuil réglementaire de 95 % sur l'ensemble des colonnes obligatoires.
Nous recommandons au Risk Officer de valider ce pipeline comme base certifiée pour le prochain entraînement du modèle de scoring de risque de contrepartie, et d'envisager son intégration dans le dispositif permanent de Data Quality Management de QuantAxis Capital.